INF6083 – Systèmes de recommandation

Projet P2 : Recommandation basée sur le contenu

Hiver 2026

Enseignant	Courriel	Local
Etienne Tajeuna	etiennegael.tajeuna@uqo.ca	A2222

Département d'Informatique et d'Ingénierie (DII)

7 mars 2026

Sommaire

Ce second projet prolonge le travail amorcé dans le projet P1 à partir du même jeu de données **Amazon Reviews 2023** dans la catégorie `Books`, mais selon une perspective différente. Alors que le premier projet portait surtout sur l'exploitation des interactions utilisateur–item dans une logique d'analyse structurelle, ce projet introduit la recommandation basée sur le contenu, où les suggestions sont produites à partir des caractéristiques descriptives des livres.

L'objectif général est de concevoir un cheminement cohérent allant de la construction des représentations d'items à l'évaluation d'un système de recommandation top-N. Les étudiants devront exploiter les métadonnées des livres, construire des profils utilisateurs à partir des items appréciés, mettre en œuvre plusieurs variantes de recommandation basée sur le contenu, puis comparer leurs comportements selon des critères quantitatifs et qualitatifs. Une attention particulière devra être portée à la qualité des représentations, à la cohérence des recommandations produites, ainsi qu'aux limites intrinsèques de cette famille d'approches.

Table des matières

1 Contexte et jeu de données **1**

1.1 Contexte 1

1.2 Jeu de données 1

1.3 Enjeux spécifiques du projet 1

2 Objectifs **2**

3 Tâches du projet **2**

3.1 Tâche 0 : Préparation des données et construction du cadre expérimental 2

3.1.1 Réutilisation du sous-ensemble de travail 2

3.1.2 Division entraînement/test 2

3.1.3 Construction des représentations d'items 3

3.1.4 Construction des profils utilisateurs 3

3.2 Tâche 1 : Recommandation par similarité de contenu 3

3.2.1 Principe 4

3.2.2 Implémentation 4

3.2.3 Analyse qualitative 4

3.3 Tâche 2 : Représentations latentes des contenus 4

3.3.1 Réduction de dimension 4

3.3.2 Projection des profils utilisateurs 5

3.3.3 Analyse 5

3.4 Tâche 3 : Apprentissage d'un score de pertinence 5

3.4.1 Formulation 5

3.4.2 Variables explicatives 5

3.4.3 Modèles 6

3.4.4 Discussion 6

3.5 Tâche 4 : Évaluation des recommandations 6

3.5.1 Évaluation quantitative 6

3.5.2 Évaluation par profils d'utilisateurs 6

3.5.3 Diversité et surspécialisation 6

3.6 Tâche 5 : Discussion générale et ouverture 7

4 Livrables **7**

4.1 Format de remise 7

1 Contexte et jeu de données

1.1 Contexte

Le filtrage basé sur le contenu constitue l'un des paradigmes fondamentaux des systèmes de recommandation, il s'appuie directement sur les propriétés descriptives des items. Dans le cas des livres, ces propriétés peuvent inclure le titre, la description, les catégories, la popularité ou encore certains attributs numériques disponibles dans les métadonnées.

Dans ce projet, l'idée centrale est la suivante : si un utilisateur a apprécié un ensemble de livres partageant certaines caractéristiques, alors il est raisonnable de lui recommander d'autres livres présentant des caractéristiques voisines. Cette logique nécessite toutefois un travail important de représentation, car les attributs disponibles sont hétérogènes, partiellement manquants et de qualité variable.

1.2 Jeu de données

Vous travaillerez avec le même sous-ensemble du jeu de données **Amazon Reviews 2023** utilisé dans le projet P1, dans la catégorie `Books`. L'objectif ici n'est donc pas de refaire tout le travail de description générale du corpus, mais de **réexploiter l'échantillon retenu** en mettant l'accent sur les **métadonnées des livres**. Le fichier `meta_Books.jsonl.gz` devient ainsi central dans ce second projet.

Les champs de métadonnées susceptibles d'être exploités incluent notamment :

— `parent_asin` : identifiant du livre ;
— `title` : titre du livre ;
— `description` : description textuelle ;
— `categories` : catégories hiérarchiques ;
— `average_rating` : note moyenne affichée ;
— `rating_number` : nombre total d'évaluations ;
— `price` : prix.

1.3 Enjeux spécifiques du projet

Ce projet se distingue du premier par la nature des informations mobilisées et par les difficultés qui en découlent. Parmi les principaux enjeux, on peut citer :

1. la construction de représentations pertinentes à partir de champs textuels et structurés ;
2. la gestion de valeurs manquantes dans les métadonnées ;
3. la fusion de sources d'information hétérogènes ;
4. la conception de profils utilisateurs dérivés des items historiquement appréciés ;
5. la tendance à la surspécialisation, fréquente dans les approches basées sur le contenu ;

6. l'évaluation de recommandations non seulement en termes de pertinence, mais aussi de diversité et de cohérence.

2 Objectifs

Ce projet vise à :

1. exploiter les métadonnées des livres pour construire des représentations d'items adaptées à la recommandation ;
2. définir une méthode de construction de profils utilisateurs à partir des livres appréciés ;
3. mettre en œuvre une première approche de recommandation basée sur la similarité contenu–profil ;
4. analyser l'effet d'une réduction de dimension sur la qualité des recommandations ;
5. proposer une variante plus avancée de recommandation basée sur l'apprentissage d'un score de pertinence ;
6. comparer les approches obtenues et discuter leurs avantages, limites et conditions d'utilisation.

3 Tâches du projet

3.1 Tâche 0 : Préparation des données et construction du cadre expérimental

3.1.1 Réutilisation du sous-ensemble de travail

Vous partirez du même jeu de travail que celui utilisé dans le projet P1, ou d'une variante proche que vous justifierez. Il n'est pas demandé de refaire un nouvel échantillonnage massif du corpus complet, sauf si cela est nécessaire pour des raisons méthodologiques clairement expliquées.

Le travail demandé dans cette première tâche consiste surtout à :

1. vérifier la qualité de la jointure entre les interactions et les métadonnées via `parent_asin` ;
2. identifier les attributs effectivement exploitables ;
3. documenter les valeurs manquantes et les choix de traitement retenus ;
4. produire un jeu de données final cohérent pour le reste du projet.

3.1.2 Division entraînement/test

La division des données devra respecter une logique compatible avec un scénario de recommandation réaliste. Une division temporelle par utilisateur est recommandée : les

interactions les plus récentes de chaque utilisateur sont réservées au test, alors que les interactions plus anciennes servent à construire les profils et les modèles.

Vous devrez :

1. expliciter la procédure retenue ;
2. garantir que chaque utilisateur présent dans le test dispose d'un historique exploitable dans l'entraînement ;
3. vous assurer qu'aucune information du test n'est utilisée lors de la construction des représentations ou du réglage des méthodes.

3.1.3 Construction des représentations d'items

Vous construirez une représentation vectorielle de chaque livre à partir des métadonnées. Cette représentation devra combiner, de manière justifiée, des informations textuelles et, si pertinent, des attributs structurés.

Une approche minimale devra inclure :

— une représentation textuelle issue du titre, de la description et/ou des catégories ;
— un prétraitement explicite des textes ;
— une vectorisation adaptée, par exemple TF-IDF ;
— l'intégration ou non d'attributs structurés, selon une stratégie argumentée.

Vous devrez aussi caractériser la représentation obtenue : dimension, densité, qualité apparente, limites observables.

3.1.4 Construction des profils utilisateurs

A partir de l'ensemble d'entraînement, vous construirez pour chaque utilisateur un profil contenu représentant ses préférences. Ce profil devra être dérivé des livres déjà consultés ou appréciés par l'utilisateur.

Vous expliciterez notamment :

1. quels items sont utilisés pour construire le profil ;
2. si les notes sont prises en compte comme pondération ;
3. comment vous gérez les utilisateurs ayant un historique très limité ;
4. quelles hypothèses implicites votre définition du profil introduit.

3.2 Tâche 1 : Recommandation par similarité de contenu

Dans cette première approche, la recommandation repose directement sur la proximité entre le profil d'un utilisateur et la représentation des livres candidats.

3.2.1 Principe

Pour chaque utilisateur cible, vous calculerez un score de pertinence entre son profil et chaque livre non encore vu dans l'ensemble d'entraînement. Une mesure de similarité adaptée devra être choisie et justifiée. La similarité cosinus est une option naturelle dans le cas de vecteurs TF-IDF, mais d'autres variantes peuvent être considérées si elles sont motivées.

3.2.2 Implémentation

Vous développerez un mécanisme de recommandation top-N permettant, pour chaque utilisateur de test, de produire une liste ordonnée de livres recommandés. L'implémentation devra être pensée de manière efficace, en tenant compte de la dimension potentiellement élevée des représentations.

3.2.3 Analyse qualitative

Au-delà des métriques quantitatives, vous proposerez une lecture qualitative des recommandations obtenues. Pour quelques utilisateurs représentatifs, vous comparerez l'historique de lecture ou d'évaluation avec les livres recommandés afin d'analyser :

— la cohérence thématique ;
— la proximité apparente entre les livres ;
— les cas de recommandations plausibles mais redondantes ;
— les situations où le modèle semble trop spécialisé.

3.3 Tâche 2 : Représentations latentes des contenus

La représentation directe des livres peut être très creuse, très grande et parfois difficile à exploiter efficacement. Cette seconde tâche vise à analyser l'intérêt d'une projection des contenus dans un espace latent de dimension plus faible.

3.3.1 Réduction de dimension

Vous appliquerez une méthode de réduction de dimension adaptée aux données textuelles, par exemple une SVD tronquée. L'objectif est d'obtenir une représentation plus compacte des livres tout en préservant une partie de l'information sémantique contenue dans les vecteurs initiaux.

Vous devrez :

1. justifier le choix de la méthode ;
2. étudier plusieurs dimensions latentes ;
3. analyser le compromis entre compacité, coût computationnel et qualité des recommandations.

3.3.2 Projection des profils utilisateurs

Les profils utilisateurs devront être exprimés dans le même espace latent que les items, afin de permettre la recommandation par similarité dans cet espace transformé.

3.3.3 Analyse

Vous comparerez les recommandations obtenues avec celles de la tâche précédente. L'analyse portera notamment sur :

— la qualité des listes recommandées ;
— l'effet de la dimension latente choisie ;
— le comportement de la méthode sur des profils utilisateurs de richesse différente ;
— l'interprétabilité ou non des dimensions latentes.

Une visualisation 2D des représentations peut être ajoutée pour appuyer votre analyse.

3.4 Tâche 3 : Apprentissage d'un score de pertinence

Cette tâche consiste à aller au-delà d'une simple similarité géométrique en formulant la recommandation comme un problème d'apprentissage. L'idée est de construire, pour un couple utilisateur–livre, un ensemble de variables explicatives permettant d'estimer un score de pertinence.

3.4.1 Formulation

Vous pourrez retenir une formulation de type :

— régression, si vous souhaitez prédire une note ;
— classification binaire, si vous souhaitez prédire si un livre sera jugé pertinent ou non ;
— apprentissage d'un score de classement, si vous souhaitez proposer une formulation plus avancée.

Le choix retenu devra être justifié au regard de l'objectif de recommandation.

3.4.2 Variables explicatives

Les variables utilisées pourront inclure, selon votre proposition :

— la représentation de l'item ;
— le profil utilisateur ;
— un score de similarité entre profil et item ;
— certaines caractéristiques globales du livre ou de l'utilisateur ;
— des transformations ou interactions que vous jugez pertinentes.

3.4.3 Modèles

Vous implémenterez au moins deux modèles d'apprentissage distincts et comparerez leur comportement. Le protocole retenu devra rester compatible avec le cadre expérimental défini en Tâche 0. Le réglage des hyperparamètres devra être expliqué de manière concise et rigoureuse.

3.4.4 Discussion

Cette partie devra montrer en quoi l'apprentissage permet, ou non, d'améliorer la recommandation par rapport aux approches plus directes. Vous discuterez aussi les coûts supplémentaires induits en termes de complexité, d'interprétabilité et de robustesse.

3.5 Tâche 4 : Évaluation des recommandations

L'évaluation doit permettre d'apprécier la qualité des recommandations produites, mais aussi d'en comprendre les forces et limites selon les utilisateurs et selon les choix de représentation.

3.5.1 Évaluation quantitative

Vous devrez définir un protocole d'évaluation hors ligne cohérent avec la nature de votre système. Les métriques de classement de type top-N sont attendues. Selon la formulation choisie en Tâche 3, des métriques supplémentaires de prédiction peuvent être ajoutées.

L'évaluation devra comparer au minimum :

— l'approche par similarité directe ;
— l'approche dans un espace latent ;
— l'approche basée sur l'apprentissage.

3.5.2 Évaluation par profils d'utilisateurs

Une attention particulière devra être portée à l'hétérogénéité des utilisateurs. Vous proposerez une analyse différenciée selon le niveau d'activité des utilisateurs, par exemple en distinguant profils peu actifs, modérément actifs et très actifs.

3.5.3 Diversité et surspécialisation

Le projet ne doit pas se limiter à la seule pertinence apparente des recommandations. Vous devrez aussi discuter la diversité intra-liste et la tendance à recommander des livres trop proches les uns des autres. Une mesure simple de diversité peut être proposée et analysée.

3.6 Tâche 5 : Discussion générale et ouverture

Dans cette dernière partie, vous proposerez une synthèse critique de votre travail. Il est attendu que vous mettiez en perspective les résultats obtenus avec les propriétés générales du filtrage basé sur le contenu.

Votre discussion devra notamment aborder :

1. les principaux enseignements tirés des différentes approches ;
2. les limites observées dans les représentations de contenu utilisées ;
3. la question du démarrage à froid pour les utilisateurs et pour les nouveaux livres ;
4. les biais possibles introduits par les métadonnées disponibles ;
5. la complémentarité entre les approches du projet P1 et celles du projet P2 ;
6. des pistes concrètes vers un système hybride combinant signaux collaboratifs et signaux de contenu.

4 Livrables

Le projet doit être réalisé par le même groupe que pour P1 (3 à 4 étudiants).

Date de remise : 22 mars 2026 au plus tard à 23h59.

4.1 Format de remise

Soumettez un fichier compressé nommé `INF6083-P2-EquipeN.zip` contenant :

1. **Rapport (PDF)** : `INF6083-P2-EquipeN-Rapport.pdf`
   - maximum 30 pages, hors annexes ;
   - structure claire suivant les tâches du projet ;
   - figures et tableaux numérotés et légendés ;
   - analyses et interprétations des résultats ;
   - le code ne doit pas être inclus dans le rapport.
2. **Code source** : `INF6083-P2-EquipeN-Code.ipynb` ou fichiers `.py`
   - code structuré et commenté ;
   - instructions d'exécution claires ;
   - fichier `requirements.txt` ;
   - fichier `README.md` expliquant l'organisation du travail ;
   - indication explicite des choix de prétraitement et du protocole d'évaluation.